



Rapport de Stage : Ingénieur IA générative H/F

Etudiant :
Jacques Masson

Maître de stage :
Christian Constantin
Directeur général

2 novembre 2026

Table des matières

I Introduction **1**

II Présentation de l'entreprise **2**

1 Le secteur d'activité **2**

2 L'entreprise **2**

3 Le service **2**
3.1 Développement de Solutions Numériques 2
3.2 Conseil en Transformation Digitale 2
3.3 Intégration de Systèmes 3
3.4 Services Cloud et Infrastructures 3
3.5 Intelligence Artificielle et Analyse de Données 3

4 Le positionnement du stage dans les travaux de l'entreprise **3**

III Travail effectué **3**

5 Le cahier des charges **4**
5.1 But Général 4
5.1.1 Première partie de stage 4
5.1.2 Deuxième partie de stage 4
5.1.3 Troisième partie de stage 4
5.2 Explication détaillée des résultats à obtenir 5
5.2.1 Les modèles d'intelligence artificielle 5
5.2.2 L'application 5

6 Compte-rendu d'activité **6**
6.1 Axes d'étude et de recherche choisis 6
6.2 Déroulement concret des études, expérimentations, mises au point... 6
6.2.1 Recherches initiales et construction des modèles 6
6.2.2 Transition vers les modèles pré-entraînés 7
6.2.3 Analyse comparative des modèles 7
6.2.4 Intégration des technologies pour la mémoire et les données 7
6.2.5 Mise en place du serveur et de l'application 7
6.2.6 Création du hub d'accès aux démonstrateurs d'IA 7
6.2.7 Outils et technologies utilisés 7
6.2.8 Évaluation des performances et difficultés rencontrées 8
6.2.9 Documentation et collaboration 8

7 Développement, interprétation et critique des résultats **8**
7.1 Principaux résultats des travaux 8
7.2 Interprétation des résultats par rapport aux objectifs initiaux 9
7.3 Succès et échecs majeurs 9
7.4 Recommandations pour améliorer les modèles et l'infrastructure 9
7.5 Utilisation et optimisation future des résultats 10

7.6 Enseignements tirés sur les plans technique et organisationnel 10

IV Conclusion générale **11**

V Bibliographie & glossaire **12**

8 Bibliographie **12**

9 Glossaire **12**

VI Annexes **13**

Première partie

Introduction

Le présent rapport présente les travaux réalisés de février 2024 à août 2024 au sein de l'entreprise B2DIGIT.

Après avoir terminé ma spécialité en intelligence artificielle, je cherchais à poursuivre mon apprentissage dans ce domaine afin de mettre en pratique mes compétences académiques et de mieux définir mes objectifs professionnels futurs. J'ai choisi de rejoindre B2DIGIT, une entreprise de conseil en informatique, car le projet proposé, consistant à créer un chatbot pour assister les salariés dans leurs interactions avec les clients, m'a grandement intéressé. Ce projet offrait l'opportunité de travailler sur une solution concrète, d'acquérir de l'expérience pratique et de contribuer à l'amélioration des conditions de travail des employés.

Un autre facteur déterminant dans ma décision a été la possibilité de m'installer à Paris, offrant un nouveau départ dans ma carrière professionnelle.

Mon stage s'est articulé autour de plusieurs phases distinctes :

1. Recherche de solutions et choix technologiques (février 2024) :
    - Définition du langage de programmation et des bibliothèques à utiliser.
    - Sélection du type de base de données.
    - Choix des serveurs pour le déploiement de la solution.
2. Développement et expérimentation (mars à mai 2024) :
    - Création de différents modèles expérimentaux.
    - Évaluation et amélioration des modèles en fonction de leurs avantages et défauts.
3. Déploiement et ajout de fonctionnalités (juin à août 2024) :
    - Mise en ligne du modèle sélectionné.
    - Ajout de fonctionnalités telles que la mémoire utilisateur, la gestion de multiples conversations par utilisateur, et la sécurisation de la plateforme d'accès.

Durant ces six mois, j'ai eu l'occasion de découvrir le processus complet de création d'une solution technologique. En étant l'une des principales personnes impliquées dans le projet, j'ai participé à toutes les étapes, ce qui m'a permis de comprendre les différents aspects et défis du développement de solutions. De plus, j'ai perfectionné mes compétences en machine learning et en traitement du langage naturel, appliquant ainsi mes connaissances académiques au monde professionnel.

Deuxième partie

Présentation de l'entreprise

1 Le secteur d'activité

B2DIGIT opère dans le secteur des technologies de l'information et de la communication (TIC), avec une spécialisation dans le développement de solutions numériques avancées et la prestation de services informatiques. Le secteur des TIC est en constante évolution, marqué par une forte demande pour des solutions innovantes permettant aux entreprises de se digitaliser et d'améliorer leur efficacité opérationnelle. B2DIGIT se positionne comme un acteur clé dans ce domaine, en offrant des services de haute qualité et en intégrant les dernières avancées technologiques pour répondre aux besoins spécifiques de ses clients.

2 L'entreprise

Fondée il y a plusieurs années, B2DIGIT s'est rapidement imposée sur le marché grâce à une stratégie de croissance axée sur l'innovation et la satisfaction client. L'entreprise a connu une forte croissance de ses capitaux permanents au cours des trois dernières années, principalement en raison des bénéfices non distribués et d'un emprunt garanti par l'État (PGE) en 2020. Cette croissance financière témoigne de la robustesse de sa gestion et de sa capacité à investir dans des projets à moyen et long terme.

Les actifs immobilisés de B2DIGIT sont relativement faibles, reflétant une stratégie centrée sur des investissements dans des biens de production essentiels comme le matériel informatique, tout en limitant les immobilisations financières à des titres de participation. Cette approche permet à l'entreprise de rester agile et de s'adapter rapidement aux évolutions du marché.

Les actifs circulants de l'entreprise ont également connu une croissance significative, notamment grâce à l'augmentation du poste clients, directement liée à l'expansion de son chiffre d'affaires. Cette croissance est soutenue par une gestion efficace des créances et des disponibilités, assurant une liquidité suffisante pour soutenir ses opérations courantes.

B2DIGIT respecte les principes d'équilibre financier, avec des passifs circulants inférieurs aux actifs circulants, garantissant ainsi une stabilité financière et une capacité à honorer ses dettes à court terme. La trésorerie nette de l'entreprise a augmenté, notamment grâce à une gestion prudente des postes clients et fournisseurs, ainsi qu'à la souscription d'un emprunt.

3 Le service

3.1 Développement de Solutions Numériques

B2DIGIT excelle dans la conception et le développement de solutions numériques sur mesure, répondant aux besoins spécifiques de ses clients. Ces solutions incluent le développement de logiciels, d'applications web et mobiles, ainsi que des plateformes de gestion de données. L'entreprise utilise des technologies de pointe pour créer des produits innovants, robustes et évolutifs.

3.2 Conseil en Transformation Digitale

L'entreprise offre des services de conseil pour aider ses clients à naviguer dans la transformation digitale. Cela inclut l'analyse des besoins technologiques, la planification stratégique, et l'accompagnement dans l'implémentation de nouvelles technologies. B2DIGIT aide les entreprises à optimiser leurs processus, améliorer leur efficacité opérationnelle et augmenter leur compétitivité sur le marché.

3.3 Intégration de Systèmes

B2DIGIT propose des services d'intégration de systèmes, permettant à ses clients de synchroniser et de faire interagir leurs différents systèmes informatiques. L'entreprise assure une intégration harmonieuse des logiciels et des systèmes existants avec de nouvelles solutions, garantissant ainsi une transition fluide et une opérationnalité sans interruption.

3.4 Services Cloud et Infrastructures

L'entreprise fournit des solutions de cloud computing, offrant à ses clients des services d'hébergement, de gestion de données, et de sauvegarde. B2DIGIT aide également à la migration vers le cloud, assurant que les données et applications de ses clients sont sécurisées et facilement accessibles. En outre, l'entreprise propose des services de gestion d'infrastructures, y compris la configuration et la maintenance de serveurs et de réseaux.

3.5 Intelligence Artificielle et Analyse de Données

B2DIGIT est à la pointe de l'intelligence artificielle (IA) et de l'analyse de données. L'entreprise développe des modèles de machine learning et des algorithmes d'IA pour aider les entreprises à exploiter pleinement leurs données. Ces services incluent la création de chatbots, l'analyse prédictive, et l'automatisation des processus métiers. B2DIGIT permet à ses clients de prendre des décisions basées sur des données concrètes et de gagner en efficacité.

4 Le positionnement du stage dans les travaux de l'entreprise

Mon stage s'est réalisé au sein de B2DIGIT et s'est déroulé en plusieurs phases. Le projet était interne à l'entreprise, et non destiné directement aux clients. L'objectif était de développer un chatbot pour assister les salariés, tout en servant de démonstrateur pour les futurs clients. Étant presque seul sur le projet, j'ai commencé par un état de l'art sur les capacités actuelles des modèles de langage (LLM, Large Language Models) et l'infrastructure nécessaire, incluant les machines virtuelles, les logiciels, les bases de données, les langages et les bibliothèques.

1. Recherche initiale et choix technologiques :
   - Effectuer des recherches sur les LLM et l'infrastructure à mettre en place.
   - Sélection des outils, technologies, et plateformes nécessaires.
2. Développement et expérimentation :
   - Développement de versions expérimentales des modèles.
   - Tests de performance pour sélectionner le modèle optimal.
   - Recherches continues pour améliorer les modèles.
3. Déploiement et finalisation :
   - Mise en ligne du modèle sélectionné.
   - Développement d'une plateforme sécurisée pour l'accès interne au chatbot.

L'entreprise travaille de manière agile, ce qui m'a permis de participer à des points journaliers avec mon maître de stage pour assurer le bon déroulement du projet et résoudre les problèmes éventuels.

Troisième partie
Travail effectué

5 Le cahier des charges

5.1 But Général

5.1.1 Première partie de stage

Cette première partie du stage, d'une durée d'un mois, s'est concentrée sur la recherche de solutions et la mise en place de toutes les infrastructures nécessaires au bon déroulement du projet. Chaque détail du projet devait être soigneusement étudié pour ne pas surestimer ou sous-estimer les ressources nécessaires.

L'étape de recherche consistait à identifier le type de modèle que nous allions utiliser et quelles bibliothèques seraient utiles. Nous avons également examiné les différentes architectures de réseaux de neurones possibles, ainsi que les avantages et les inconvénients de chaque approche. Une attention particulière a été portée à la compatibilité des technologies avec les systèmes existants de l'entreprise.

Technologies explorées :

- **Langages de programmation** : Python
- **Bibliothèques et frameworks** : TensorFlow, PyTorch, Scikit-learn, Keras
- **Bases de données considérées** : PostgreSQL, MySQL, MongoDB

L'étape de recherche a également inclus une évaluation des ressources matérielles nécessaires, telles que les serveurs, les GPU pour l'entraînement des modèles, et les besoins en stockage. Nous avons analysé les coûts associés à ces ressources pour établir un budget précis.

5.1.2 Deuxième partie de stage

Une fois les recherches terminées, l'objectif de la deuxième partie était de créer un ou plusieurs modèles performants capables de réaliser les mêmes types de tâches qu'un chatbot de type ChatGPT, mais avec la contrainte supplémentaire de pouvoir répondre à des questions spécifiques à l'entreprise. Une fois le modèle développé, il fallait ajouter différents programmes pour le rendre utilisable avant de le mettre en ligne.

Des tests rigoureux ont été effectués pour évaluer la robustesse des modèles, y compris des scénarios de cas d'utilisation spécifiques à l'entreprise. Des ajustements et des itérations ont été nécessaires pour affiner les modèles et améliorer leur performance.

5.1.3 Troisième partie de stage

La dernière partie du stage était consacrée à la mise en ligne du projet. Il était essentiel de créer une application hébergée sur un serveur sécurisé, accessible uniquement aux membres de l'entreprise. J'ai opté pour un serveur Apache pour l'hébergement, et j'ai mis en place le protocole SSL pour assurer que toutes les communications soient chiffrées et sécurisées via HTTPS.

Pour le développement de l'application, j'ai utilisé le framework Flask pour le backend et HTML/CSS et Javascript pour le frontend, ce qui a permis de construire une interface utilisateur moderne et réactive. La sécurisation de l'application a été renforcée par l'intégration d'un système d'authentification OAuth, géré via une API Google, permettant aux utilisateurs de se connecter avec leur adresse e-mail professionnelle.

5.2 Explication détaillée des résultats à obtenir

5.2.1 Les modèles d'intelligence artificielle

Mon travail consistait à coder un modèle d'intelligence artificielle, dit LLM (Large Language Model). Les LLM sont des modèles d'intelligence artificielle ayant un nombre très conséquent de paramètres, souvent plusieurs milliards, ce qui leur permet de comprendre et de générer du texte de manière très sophistiquée.

Les LLM fonctionnent en apprenant des motifs à partir de vastes ensembles de données textuelles, leur permettant de prédire le mot suivant dans une séquence ou de générer des réponses à des questions complexes. Ils sont utiles pour une variété de tâches, allant de la traduction automatique à la génération de contenu, en passant par la modélisation du dialogue.

L'objectif était donc de créer un modèle aussi conséquent avec peu de moyens, ou du moins de trouver une solution pour y parvenir. Initialement, l'objectif final était de développer plusieurs modèles, chacun spécialisé dans une tâche précise, comme la traduction, la réponse précise aux questions, la correction de texte, etc.

Après plusieurs essais de modèles créés de toutes pièces, nous n'avons pas réussi à construire un modèle assez performant. Nous nous sommes donc tournés vers des modèles pré-entraînés. L'avantage de ces modèles est qu'ils ne nécessitent pas de faire le premier entraînement, ce qui permet au modèle de comprendre toute la complexité de la langue française. Il a donc fallu revoir notre infrastructure pour importer un modèle déjà entraîné et le remodeler pour notre tâche. L'objectif a alors changé : au lieu de développer plusieurs modèles, chacun spécifique à une tâche, nous devions trouver et optimiser le modèle le plus performant pour répondre à toutes les demandes possibles. Il a également fallu configurer une machine virtuelle et un serveur assez puissants pour fournir les ressources nécessaires au modèle choisi, qui reste très exigeant en termes de calculs même après son entraînement initial.

Une fois cela fait, nous avons ajouté Langchains au projet, une bibliothèque permettant la gestion en mémoire des conversations avec les utilisateurs. Enfin, nous avons intégré Pinecone, un outil permettant de créer des bases de données vectorisées, pour y ajouter les données de l'entreprise.

5.2.2 L'application

La dernière partie de mon stage était consacrée à la création d'un serveur permettant d'héberger tout le projet. L'objectif était de développer une application sécurisée permettant aux salariés de tester le modèle et de corriger les différents problèmes. Dans un premier temps, il a fallu créer un serveur Apache, puis mettre en place le protocole SSL pour que le site soit en HTTPS et offre une sécurité accrue. Nous avons utilisé une API Google pour gérer les connexions via adresse mail. Une fois tout mis en place, il a également fallu gérer le design du site pour qu'il soit attrayant. Enfin, nous avons créé un hub permettant d'accéder au chatbot, avec la possibilité d'ajouter plusieurs démonstrateurs d'intelligence artificielle à l'avenir.

En créant l'application, nous avons identifié des fonctionnalités supplémentaires à ajouter. Cela inclut la possibilité pour chaque utilisateur d'avoir un historique de conversation personnel et la capacité de gérer plusieurs conversations simultanément, chacune avec son propre historique, afin de retrouver une session précise sans perturber la mémoire avec des questions auxiliaires.

6 Compte-rendu d'activité

6.1 Axes d'étude et de recherche choisis

Les principaux axes de recherche de mon projet ont été guidés par plusieurs sources. Tout d'abord, j'ai revisité mes cours d'intelligence artificielle pour cibler au mieux le projet. Ensuite, j'ai cherché des projets similaires sur Internet pour m'inspirer et comprendre les meilleures pratiques. Github et Hugging Face ont été des ressources essentielles, où j'ai trouvé des modèles, des exemples de code, et des projets open-source liés à mon domaine. Enfin, certains tutoriels sur YouTube m'ont aidé à surmonter des obstacles spécifiques dans certaines tâches.

Pour évaluer les différentes solutions technologiques, j'ai principalement pris en compte la simplicité de mise en œuvre en fonction des ressources dont je disposais. Étant donné que j'avais choisi Python et PyTorch comme base, j'ai concentré mes recherches sur les solutions qui étaient les plus simples et intuitives à intégrer dans cet environnement.

Le choix de PyTorch plutôt que TensorFlow a été motivé par sa flexibilité et sa communauté active, qui offrait un soutien précieux tout au long du projet. Par exemple, la documentation officielle de PyTorch est plus accessible pour les débutants, et ses forums de support sont particulièrement actifs, ce qui m'a permis de résoudre rapidement les problèmes techniques que j'ai rencontrés.

Le choix des modèles a été guidé par un critère principal : la capacité à comprendre et à traiter le français. Pour l'infrastructure, le budget disponible a été un facteur déterminant dans les décisions prises, notamment en ce qui concerne les ressources matérielles nécessaires.

Dans le cadre de mes recherches sur les modèles pré-entraînés, j'ai consulté plusieurs articles académiques publiés par des leaders du domaine comme OpenAI et Google. Par exemple, l'article de Google sur BERT m'a fourni une compréhension approfondie des mécanismes internes des modèles de langage, ce qui m'a aidé à adapter CamemBERT pour notre projet. J'ai également exploré des forums de discussion et des communautés en ligne, comme Stack Overflow et Reddit, où des experts partageaient leurs expériences sur l'optimisation des modèles LLM pour des tâches spécifiques.

Au fil du projet, j'ai dû adapter mes axes d'étude à plusieurs reprises. Après avoir rencontré des problèmes de ressources avec des modèles créés de toutes pièces, j'ai commencé à explorer des modèles pré-entraînés. Cette recherche m'a permis de découvrir plusieurs options avant de trouver le modèle le plus adapté à nos besoins. De plus, j'ai dû faire des recherches supplémentaires pour la mise en place des serveurs et de l'application, car c'était un domaine où j'avais initialement peu d'expérience.

Quant à la hiérarchisation des axes d'étude, j'ai priorisé les recherches selon l'urgence et l'impact potentiel sur le projet. Par exemple, trouver un modèle performant était crucial pour avancer, donc cela a pris la priorité sur d'autres aspects comme l'infrastructure.

6.2 Déroulement concret des études, expérimentations, mises au point...

Le projet s'est déroulé en plusieurs phases, chacune marquée par des recherches, des expérimentations, et des ajustements constants.

6.2.1 Recherches initiales et construction des modèles

Dans un premier temps, j'ai effectué des recherches approfondies pour déterminer comment structurer le projet. J'ai commencé par construire plusieurs modèles de toute pièce. Lors des premières tentatives de construction de modèles, j'ai utilisé des datasets lourds, comprenant des millions de phrases en français provenant de sources diverses comme Wikipedia, des articles de presse, et des bases de données textuelles ouvertes. Le traitement de ces données a posé des défis, notamment en termes de prétraitement et de nettoyage des données pour éliminer les biais et les incohérences. Pour cela, j'ai utilisé des techniques avancées de text mining, incluant la détection des outliers et la normalisation des données linguistiques.

Cependant, ces tentatives se sont révélées infructueuses en raison des limitations de ressources, ce qui m'a conduit à rechercher des modèles pré-entraînés.

6.2.2 Transition vers les modèles pré-entraînés

Après plusieurs essais, j'ai commencé à travailler avec CamemBERT, une version de BERT spécialisée dans la langue française. Cependant, ce modèle ne répondait pas à nos attentes, ce qui m'a poussé à explorer d'autres options. Finalement, j'ai trouvé une version de MistralAI qui s'est avérée bien plus efficace pour notre projet.

6.2.3 Analyse comparative des modèles

Avant de sélectionner MistralAI comme modèle principal, j'ai exploré plusieurs autres options, notamment CamemBERT et GPT-2. CamemBERT, bien qu'optimisé pour le français, présentait des limitations en termes de performance sur les tâches spécifiques de l'entreprise, notamment dans la compréhension contextuelle des questions complexes. GPT-2, bien que puissant, nécessitait des ressources d'entraînement considérables qui n'étaient pas alignées avec notre budget. En comparaison, MistralAI a offert un bon compromis entre performance et ressources nécessaires, avec une capacité à généraliser sur des tâches diverses tout en restant performant dans un environnement à ressources limitées.

6.2.4 Intégration des technologies pour la mémoire et les données

Une fois le modèle sélectionné, j'ai intégré Langchains pour gérer la mémoire des conversations et Pinecone pour l'ajout des données spécifiques à l'entreprise. L'intégration de Langchains a nécessité une adaptation de l'infrastructure pour gérer la mémoire des conversations utilisateur. J'ai dû configurer un pipeline de traitement spécifique pour s'assurer que les données en mémoire soient correctement stockées et accessibles en temps réel, tout en respectant les contraintes de performance du modèle. Pinecone a été utilisé pour créer des bases de données vectorisées, ce qui a permis de stocker et de récupérer rapidement des informations complexes, facilitant ainsi des réponses précises et contextualisées par le chatbot.

6.2.5 Mise en place du serveur et de l'application

Ensuite, nous avons configuré un serveur Apache avec Gunicorn pour gérer l'application Flask. La sécurisation du serveur a été assurée par le protocole SSL, et une API Google a été utilisée pour sécuriser l'accès à l'application. Cette phase a également inclus des ajustements pour améliorer le modèle et ajouter des fonctionnalités supplémentaires, comme un historique personnalisé pour chaque utilisateur et la possibilité de gérer plusieurs conversations simultanées.

6.2.6 Création du hub d'accès aux démonstrateurs d'IA

En dernier lieu, nous avons créé un hub qui permet aux utilisateurs de naviguer entre différents démonstrateurs d'intelligence artificielle, offrant une interface centralisée pour tester les différentes fonctionnalités développées.

6.2.7 Outils et technologies utilisés

- **Langages et frameworks** : Python et PyTorch pour le développement des modèles, Flask pour la création de l'application web.
- **Serveurs et infrastructure** : Apache et Gunicorn pour un serveur performant, sécurisé, et gratuit ; une machine virtuelle avec GPU Azure pour supporter les besoins en calcul ; bases de données SQL pour gérer les historiques de conversation.

- **Outils pour la mémoire et les données** : Langchains pour la gestion de la mémoire des conversations, Pinecone pour l'ajout des données spécifiques à l'entreprise.
- **Sécurisation** : API Google pour l'authentification des utilisateurs, SSL pour sécuriser les communications.
- **Gestion du code** : GitHub a été utilisé pour la gestion et la sauvegarde du code source.

6.2.8 Évaluation des performances et difficultés rencontrées

Pour évaluer les performances des modèles, j'ai commencé par des tests de type BLEU et ROUGE sur les premiers modèles, mais ces évaluations ont été suivies de tests plus orientés sur la capacité des modèles à répondre correctement aux questions spécifiques à l'entreprise. Les tests BLEU et ROUGE que j'ai utilisés au début m'ont fourni une première évaluation de la qualité des modèles en termes de similarité textuelle. Cependant, j'ai rapidement constaté que ces métriques, bien qu'importantes, ne suffisaient pas pour capturer toute la complexité des réponses attendues. J'ai donc complété ces tests par des évaluations basées sur des scénarios réels, où le chatbot devait répondre à des questions spécifiques de l'entreprise. Ces tests ont révélé des lacunes dans la compréhension contextuelle du modèle, ce qui m'a poussé à affiner davantage l'entraînement du modèle avec des données plus ciblées.

Après le déploiement initial du chatbot, les employés de l'entreprise ont pu tester le chatbot pour recueillir leurs retours. Les utilisateurs ont apprécié la capacité du chatbot à comprendre des requêtes complexes, mais ont également souligné des domaines d'amélioration, tels que l'interface utilisateur et la rapidité des réponses dans certaines conditions. Ces retours ont été précieux pour ajuster l'application et prioriser les développements futurs.

J'ai rencontré plusieurs difficultés majeures tout au long du projet. Le développement de modèles de toute pièce s'est avéré très compliqué en raison des ressources limitées, ce qui m'a poussé à me tourner vers des modèles pré-entraînés. Ensuite, des problèmes de performance ont nécessité l'utilisation d'une machine virtuelle puissante. Enfin, la création du site web a également posé des défis, notamment en termes de sécurité et d'intégration avec l'API Google, mais avec l'aide d'un collègue et une documentation approfondie, nous avons surmonté ces obstacles.

6.2.9 Documentation et collaboration

Tout au long du projet, j'ai produit une documentation complète pour assurer la continuité et la maintenabilité du travail effectué. Cela inclut des guides d'installation pour les outils nécessaires, des manuels d'utilisation pour l'application web, et des documents techniques détaillant l'architecture du modèle et les configurations du serveur. Ces documents ont été rédigés avec une attention particulière pour qu'ils soient accessibles aux futurs développeurs, facilitant ainsi la reprise du projet ou l'intégration de nouvelles fonctionnalités.

Pour documenter le projet, j'ai conservé des archives de tous les modèles développés, avec des commentaires détaillés dans le code. Des fichiers README ont été créés pour chaque étape majeure, et j'ai maintenu un carnet de notes détaillant le déroulement du stage.

La collaboration avec un collègue a été essentielle, notamment pour la gestion des paramètres de la machine virtuelle et l'intégration de l'API Google. Cette collaboration nous a permis de résoudre rapidement les problèmes techniques et d'avancer efficacement sur le projet.

7 Développement, interprétation et critique des résultats

7.1 Principaux résultats des travaux

Les résultats obtenus au cours de ce projet sont globalement très satisfaisants. Le chatbot développé fonctionne de manière fluide et est capable de répondre de manière pertinente et précise aux questions

posées, ce qui démontre une bonne performance du modèle sous-jacent. L'application web, conçue pour héberger ce chatbot, s'est avérée sécurisée et intuitive, permettant une utilisation facile pour les employés de l'entreprise. Nous avons ainsi réussi à atteindre les objectifs principaux du projet : développer un chatbot fonctionnel et créer une application conviviale et sécurisée. À ce stade, le projet est considéré comme un succès, bien qu'il reste encore des possibilités d'amélioration, notamment en termes de performances et de fonctionnalités supplémentaires.

7.2 Interprétation des résultats par rapport aux objectifs initiaux

En examinant les résultats obtenus par rapport aux objectifs initiaux, il est clair que le projet a globalement atteint ses principales ambitions. Cependant, il est important de noter une divergence par rapport aux plans initiaux. L'objectif initial était de créer un modèle de traitement du langage naturel (NLP) "from scratch", c'est-à-dire en le construisant entièrement en interne. Toutefois, en raison des contraintes de ressources et du temps, nous avons dû nous tourner vers des modèles pré-entraînés, ce qui a marqué un écart significatif par rapport au plan initial. Bien que cette décision ait permis de compléter le projet dans les délais, elle représente une certaine limitation en termes d'originalité et de contrôle sur le modèle.

7.3 Succès et échecs majeurs

Parmi les succès notables du projet, on peut citer le bon fonctionnement du chatbot, qui remplit parfaitement son rôle en répondant de manière adéquate aux questions des utilisateurs. L'application elle-même a également été un succès, en étant à la fois sécurisée et intuitive, ce qui était essentiel pour son adoption par les utilisateurs internes. Ces succès témoignent de la solidité des choix technologiques et de l'efficacité de la mise en œuvre.

En revanche, le projet a également rencontré des échecs notables. Le principal échec a été l'incapacité à créer un modèle "from scratch" comme initialement prévu, ce qui a conduit à l'utilisation de modèles pré-entraînés. Bien que cette approche ait permis de gagner du temps, elle a limité notre capacité à personnaliser le modèle selon les besoins spécifiques de l'entreprise. De plus, la configuration du serveur et de l'application a pris beaucoup plus de temps que prévu, ce qui a retardé le développement d'autres fonctionnalités. Ce retard a limité notre capacité à enrichir l'application avec des fonctionnalités supplémentaires qui auraient pu apporter une valeur ajoutée.

L'un des défis majeurs rencontrés a été la configuration du serveur et de l'application. La mise en place d'une infrastructure capable de supporter un modèle NLP de cette envergure tout en assurant une sécurité robuste a nécessité plusieurs itérations. Le principal problème technique était lié à la gestion des ressources GPU sur la machine virtuelle Azure, où nous avons dû optimiser les paramètres pour éviter les goulots d'étranglement pendant les périodes de charge maximale. Une autre difficulté résidait dans l'intégration de Langchains pour la gestion de la mémoire des conversations, où des conflits de compatibilité avec d'autres bibliothèques ont nécessité des ajustements du code.

7.4 Recommandations pour améliorer les modèles et l'infrastructure

En termes d'améliorations, plusieurs recommandations peuvent être formulées. Tout d'abord, l'architecture globale du projet pourrait bénéficier d'une révision. Actuellement, elle fonctionne, mais elle manque de clarté et de structure, ce qui rendrait difficile pour quelqu'un de nouveau sur le projet de le comprendre et de le maintenir efficacement. Une documentation plus rigoureuse et une réorganisation de l'architecture permettraient d'améliorer la maintenabilité du projet.

Du côté des modèles, il serait pertinent d'améliorer leur capacité à intégrer des informations très récentes, ce qui leur permettrait de répondre de manière plus pertinente aux questions contextuelles. De plus, la gestion de Langchains pourrait être optimisée, et l'intégration de nouvelles données dans Pinecone pourrait enrichir la base de connaissances du chatbot, le rendant encore plus performant et utile.

Pour améliorer l'architecture du projet, il serait pertinent d'envisager une refonte complète du code source, en appliquant des principes de programmation modulaire. Cela permettrait de simplifier la maintenance et de faciliter l'ajout de nouvelles fonctionnalités. Sur le plan de la performance du modèle, un programme de mise à jour continue basé sur l'apprentissage en ligne pourrait être implémenté. Cela permettrait au chatbot de rester pertinent en intégrant des données récentes au fur et à mesure. Enfin, l'intégration de technologies de surveillance comme Prometheus pour le monitoring des performances en temps réel pourrait aider à détecter rapidement les problèmes et à ajuster les paramètres en conséquence.

La sécurité de l'application a été une priorité tout au long du projet. L'utilisation du protocole SSL assure que toutes les communications entre l'application et les utilisateurs sont cryptées, ce qui réduit considérablement le risque d'interception des données. De plus, l'intégration de l'API Google pour l'authentification permet de s'assurer que seuls les utilisateurs autorisés peuvent accéder au chatbot. Cependant, une évaluation de la sécurité a révélé que certaines zones de l'application pourraient être renforcées, notamment en implémentant des politiques de gestion des accès plus granulaires et en ajoutant des mécanismes de détection d'intrusion pour prévenir les attaques potentielles.

7.5 Utilisation et optimisation future des résultats

Les résultats de ce projet sont transférables et adaptables, ce qui en fait une base solide pour de futures évolutions. L'infrastructure mise en place pourrait être réutilisée dans d'autres contextes en modifiant simplement les données et le design de l'application pour l'adapter à de nouveaux besoins. Cela rend le projet flexible et capable d'évoluer avec les besoins changeants de l'entreprise ou d'autres clients potentiels.

Le déploiement du chatbot représente une opportunité majeure pour automatiser certaines tâches répétitives au sein de l'entreprise, comme la réponse aux questions fréquentes des employés ou des clients. Cette automatisation pourrait libérer du temps pour les employés, leur permettant de se concentrer sur des tâches plus complexes et à plus forte valeur ajoutée. Par exemple, en automatisant le service client de premier niveau, l'entreprise pourrait non seulement améliorer la réactivité et la disponibilité des réponses, mais aussi réduire les coûts liés à la gestion manuelle de ces interactions.

7.6 Enseignements tirés sur les plans technique et organisationnel

Sur le plan technique, ce projet m'a appris l'importance de prêter une attention particulière à l'architecture d'un projet dès le début. Une architecture mal conçue peut entraîner des complications à long terme, rendant le projet plus difficile à maintenir et à développer. J'ai également appris les différentes étapes de conception, et pourquoi chacune d'entre elles est cruciale pour assurer la réussite d'un projet.

Sur le plan organisationnel, le fait de travailler en méthode agile avec des points réguliers m'a permis de rester concentré sur les tâches les plus importantes à chaque étape du projet. Cette approche a favorisé une meilleure gestion du temps et a permis de s'adapter rapidement aux imprévus, améliorant ainsi la qualité du résultat final.

Quatrième partie

Conclusion générale

Ce stage chez B2DIGIT m'a offert une opportunité unique de travailler sur un projet concret d'intelligence artificielle, avec pour objectif principal de développer un chatbot destiné à aider les salariés de l'entreprise dans leurs interactions avec les clients. Le cahier des charges du projet était ambitieux : il s'agissait de créer un modèle capable de comprendre et de répondre à des questions spécifiques à l'entreprise, tout en développant une application sécurisée et intuitive pour l'héberger.

Dès le départ, le travail a été clairement délimité en plusieurs phases, allant de la recherche de solutions et de l'identification des technologies adéquates, à la mise en place des infrastructures nécessaires, puis au développement et à l'intégration des modèles d'intelligence artificielle. J'ai d'abord exploré la possibilité de créer un modèle from scratch, mais face aux contraintes de ressources, j'ai finalement opté pour l'utilisation de modèles pré-entraînés, ce qui a permis d'atteindre les objectifs dans les délais impartis.

Mes axes de recherche ont principalement porté sur l'optimisation du modèle choisi, l'intégration de Langchains pour la gestion de la mémoire des conversations, et l'utilisation de Pinecone pour enrichir les données spécifiques à l'entreprise. Les résultats obtenus ont été satisfaisants, avec un chatbot performant et une application sécurisée, bien que des améliorations soient encore possibles, notamment en termes de fonctionnalités et de performance du modèle. L'originalité de ce travail réside dans l'intégration harmonieuse de technologies avancées pour répondre aux besoins spécifiques de B2DIGIT, tout en s'inscrivant dans le cadre plus large des initiatives de transformation digitale de l'entreprise.

Ce stage m'a apporté une compréhension approfondie de la gestion de projet dans un contexte professionnel, en particulier dans le domaine de l'intelligence artificielle. Il m'a permis de renforcer mes compétences techniques en programmation et en architecture de projet, tout en me confrontant aux réalités du développement technologique en entreprise. En retour, j'ai apporté à B2DIGIT une solution fonctionnelle qui pourra être développée et améliorée à l'avenir pour continuer à soutenir les salariés de l'entreprise dans leurs missions. Mon travail a également contribué à poser les bases d'un projet qui pourra évoluer avec les besoins de l'entreprise, tout en offrant une base solide pour les futurs développements.

Cinquième partie

Bibliographie & glossaire

8 Bibliographie

- **Documentation Github**
- **Documentation Python**
- **Documentation Pytorch**
- **Documentation Flask**
- **Documentation Langchains**
- **Documentation Pinecone**
- **Documentation SSL**
- **Documentation OAuth**
- **Documentation Apache**

9 Glossaire

- **GitHub** : Plateforme de développement collaboratif qui utilise Git pour le contrôle de version de code source, facilitant la gestion de projets logiciels complexes.
- **Python** : Langage de programmation interprété, polyvalent, utilisé pour une large gamme d'applications, de l'automatisation de scripts aux systèmes d'intelligence artificielle.
- **PyTorch** : Bibliothèque open-source de machine learning, particulièrement utilisée pour le développement de modèles de deep learning, notamment dans le domaine du traitement du langage naturel.
- **Flask** : Micro-framework web en Python, utilisé pour créer des applications web légères et modifiables.
- **Langchains** : Bibliothèque permettant la gestion de la mémoire conversationnelle dans un chatbot, en maintenant un contexte cohérent tout au long d'une session utilisateur.
- **Pinecone** : Service de base de données vectorielles, facilitant le stockage et la recherche d'informations complexes, souvent utilisées dans les applications d'intelligence artificielle.
- **SSL (Secure Sockets Layer)** : Protocole de sécurité qui établit une connexion cryptée entre un serveur web et un navigateur, assurant la confidentialité et l'intégrité des données échangées.
- **OAuth** : Protocole standard d'autorisation permettant à une application d'accéder à des ressources sécurisées sur un serveur au nom d'un utilisateur, souvent utilisé pour l'authentification via des services tiers.
- **Apache** : Serveur web open-source utilisé pour héberger des sites web et des applications, compatible avec de nombreux modules pour étendre ses fonctionnalités.

Sixième partie

Annexes

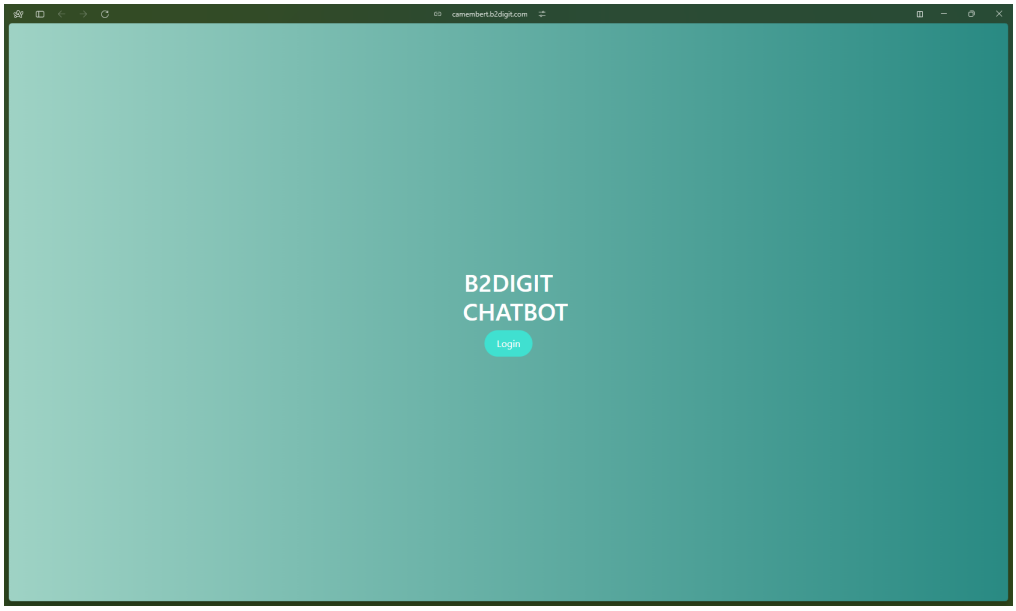


FIGURE 1 – Image du login du site

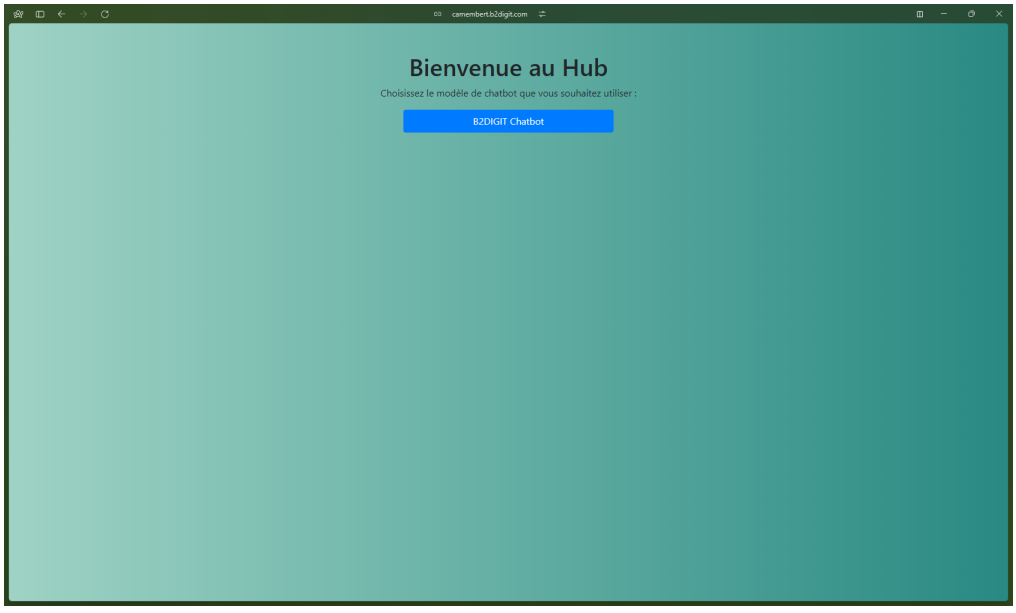


FIGURE 2 – Image du Hub du site

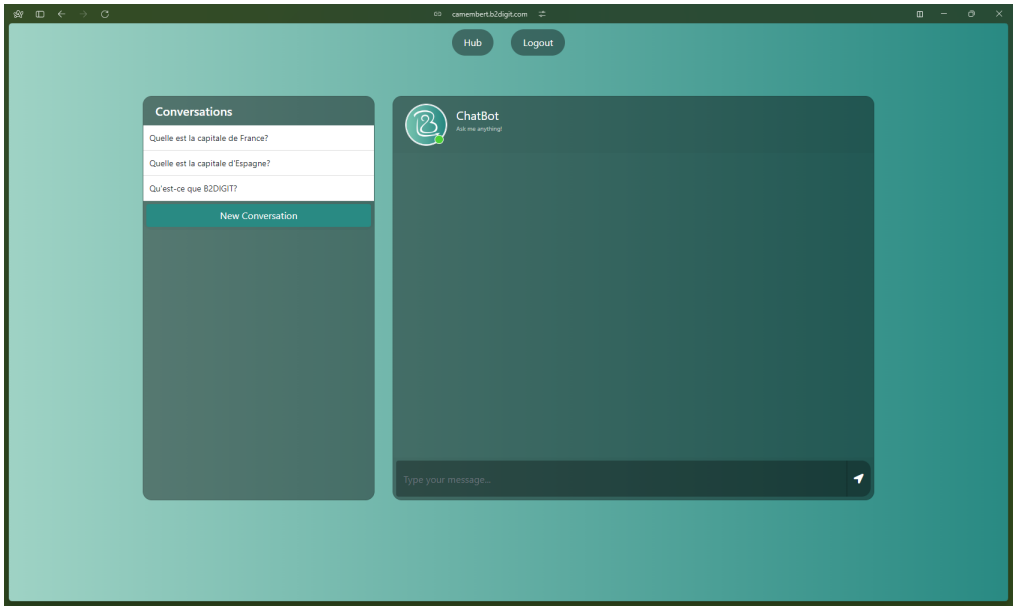


FIGURE 3 – Image de l'interface utilisateur du chatbot